

Grupa 1:

Ciupek Dominika

Kwiek Patrycja

Pstrusiński Teodor

Stafiej Aleksandra

Plan projektu:

1. Normalizacja danych
2. Wykrywanie obiektów - wyodrębnienie całych nerek z wykorzystaniem funkcji `random walker`:

```
skimage.segmentation.random_walker(data, labels, beta=130, mode='cg_j',  
tol=0.001, copy=True, multichannel=False, return_full_prob=False,  
spacing=None)
```
3. Segmentacja nowotworu z wykorzystaniem histogramów:
 - rozszerzyć histogram w zakresach odcieni szarości nowotworu
 - threshold na podstawie Otsu (funkcja z zajęć)
 - Canny edge detector do wykrycia krawędzi nowotworów
4. Stworzenie funkcji, która na wejście przyjmie zbiór obrazów, a zwracać będzie zbiór obrazów z nałożonymi maskami binarnymi

Ewaluacja wyników w tym przypadku wykonana by była za pomocą porównania otrzymanych przez nas wyników z danymi segmentacji dostępnymi w challenge, bądź poprzez wykorzystanie itk-SNAP.

Podział ról:

- pierwsza osoba: wykrywanie obiektów
- druga osoba: segmentacja nowotworu
- trzecia osoba: normalizacja danych + złożenie funkcji w całość
- czwarta osoba: ewaluacja wyników

Jednakże, pomimo podziału na role, każda osoba będzie miała udział w przygotowaniu poszczególnych części projektu.

Alternatywą do przedstawionego rozwiązania byłoby napisanie kodu opartego o sieci neuronowe (przedstawione rozwiązania znalezione w artykułach naukowych). Problemem w przedstawionym rozwiązaniu byłby brak odpowiedniej mocy obliczeniowej. Możliwym jest, iż brakłoby czasu na wykonanie zadania.

Przykładowy algorytm, na którym byśmy się wzorowali:

<https://medium.com/@fabio.sancinetti/u-net-convnet-for-ct-scan-segmentation-6cc0d465eed3>

W wypadku wykorzystania sieci neuronowych możliwym byłaby ewaluacja wyników na podstawie dice similarity:

<https://medium.com/datadriveninvestor/deep-learning-in-medical-imaging-3c1008431aaf>